Отчет по проекту

Тема: «Для каких типов рядов какая трансформация ряда полезнее?»

Состав команды:

1. Алдаров Артем Константинович

Постановка задачи

Задачей данного проекта является аналитика того, какие трансформации лучше всего подходят для кластеризованных временных рядов, сэплированных из датасета M4 Monthly.

Описание данных

Датасет M4 Monthly состоит из 100 тысяч временных рядов различной длины из различных доменов: демография, микроб макро, промышленность, финансы и др.

Все ряды представлены в едином формате:

- ‘series_name’ – название ряда типа «TX», где X – порядковый номер ряда в датасете
- ‘start_timestamp’ – время начала отсчета в формате ISO
- ‘series_value’ – массив значений ряда

Ход работы

Ход работы может быть разложен на следующие шаги:

1. Конвертация датасета из формата .tsf в pandas.DataFrame

Для конвертации берём функцию convert_tsf_to_dataframe(), написанную создателями исходного датасета.

2. Сэмплирование 100 случайных рядов из датасета

Перед сэмплированием отфильтровываем все ряды, длина которых меньше 240 точек. Сэмплируем ряды с помощью NumPy.

3. Перевод сэмплированных рядов в Long-формат и их обрезка первыми 240 значениями

4. Разделение каждого ряда на обучающую и тестовую выборки

При разделении на выборки берём горизонт прогнозирования, равный 24 месяцам.

5. Кластеризация рядов на оптимальное число кластеров, найденное методом локтя

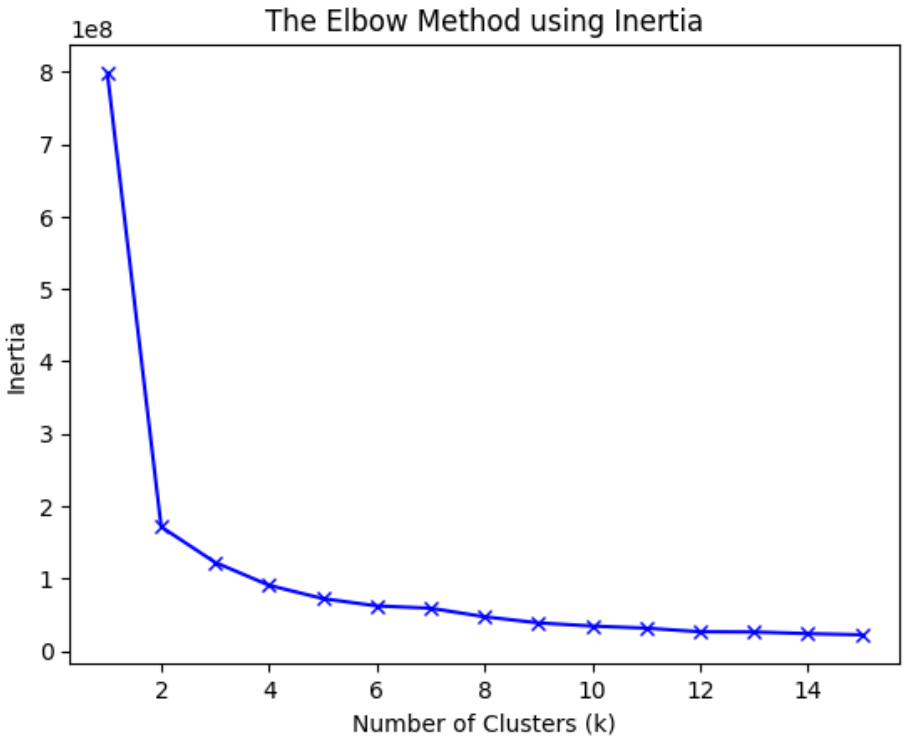

Из рисунка выше видим, что оптимальное число кластеров – 8. Сами кластеры имеют вид:

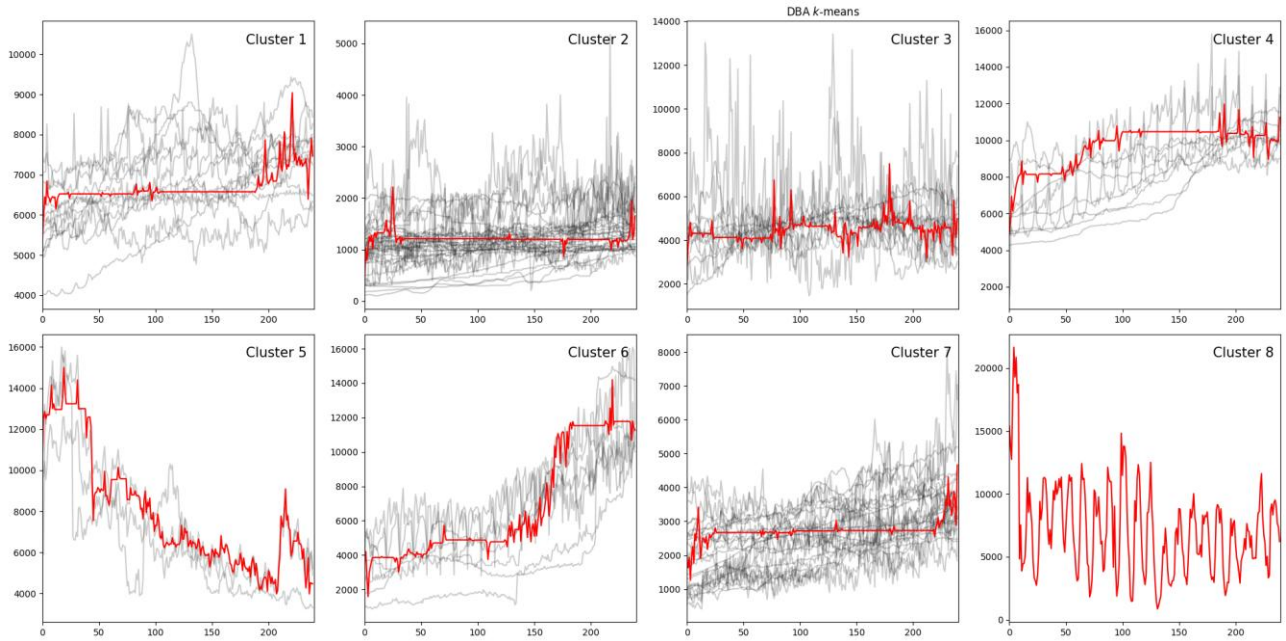

Видим, что сэмплированные ряды имеют разные масштабы значений.

6. Для каждого ряда строим бейзлайны:
    - Naive
    - SeasonalNaive
    - AutoETS
    - AutoTheta

Так как ряды имеют разную природу и могут как иметь сезонность, так и не иметь, то ни один из бейзлайнов отвергнуть не можем.

7. Трансформируем ряды:
    - Нет трансформации
    - Log1p
    - Box-Cox
    - Дифференцирование ряда
8. При применении каждой из трансформаций на каждом из кластеров обучаем CatBoost, предсказания делаем для каждого ряда на 24 точки вперёд
9. Считаем качество предсказаний бейзлайнов и сравниваем его с качеством CatBoost при разных трансформациях по набору метрик:
    - MAPE (лосс CatBoost в данном проекте)
    - sMAPE
    - MASE

Данные метрики хороши тем, что не зависят от масштаба

10. Для каждого из кластеров смотрим, какая трансформация является лучшей по каждой метрике качества в отдельности
11. Делаем выводы о лучшей трансформации

Описание моделей

Используем глобальную модель CatBoost с параметрами:

- n_iterations=1000
- depth=6

Для бейзлайнов задаём season/season_length=12 (так как в году 12 месяцев), freq='ME' (помесячные данные).

Результаты

Для всех кластеров получилось, что лучшая трансформация – её отсутствие, поэтому посмотрим «вторую по качеству» трансформацию:

Кластер	Число рядов в кластере	Лучшая трансформация		
		MAPE	sMAPE	MASE
1	17	Log1p	Log1p	Log1p
2	14	Log1p	Log1p	Log1p
3	3	Box-Cox	Box-Cox	Box-Cox, дифференцирование
4	12	дифференцирование	дифференцирование	дифференцирование
5	22	-	-	-
6	1	дифференцирование / Log1p	дифференцирование	дифференцирование
7	27	дифференцирование	дифференцирование	дифференцирование
8	4	Log1p	Log1p	Log1p

Вывод

Хоть и в нашем случае это не так, для предсказания рядов разной природы и вида оптимальны различные трансформации, все из которых (при наличии вычислительных мощностей) должны быть рассмотрены.

Самыми полезными из «вторых по качеству» трансформаций в нашем примере являются логарифмирование и дифференцирование (по 3 кластера)